Séance 2 : Les données, leurs propriétaires et leurs défauts

Jeudi 5 novembre, 11h30 à 15h30, présentiel. Deux sorties d'information : 11h30 et 14h. Rendu 1 à 15h30.

Sommaire

- La règle
- L'histoire de Julien
  - La belle diapositive
  - Première surprise : les données ne sont pas à lui
  - Deuxième surprise : le chemin impose le rythme
  - Troisième surprise : la donnée a un défaut
  - Quatrième surprise : impossible de relier les deux
  - Et combien ça pèse ?
- En résumé
- Exercice flash, 5 minutes
- Déroulé
- Livrable L2 : inventaire des données
- À la fin de la séance

La règle

Une donnée a toujours un propriétaire, un chemin et un défaut.

Sur un schéma, une source de données est une boîte avec une flèche. Dans la réalité, quelqu'un peut vous en refuser l'accès, elle arrive par un chemin qui impose son rythme, et elle a des défauts que seuls ceux qui la produisent connaissent.

L'histoire de Julien

La belle diapositive

Julien est responsable logistique chez un transporteur : 500 camions, des milliers de livraisons par semaine. Il veut deux choses : mesurer la ponctualité, et prévenir un client dès qu'une livraison prend du retard.

Le prestataire lui présente une diapositive très simple. Une boîte « GPS des camions », une boîte « horaires de livraison », une flèche vers un tableau de bord. Trois semaines de travail, annonce-t-il. Il en faudra trois mois.

Première surprise : les données ne sont pas à lui

Les boîtiers GPS n'appartiennent pas au transporteur. Ils appartiennent au loueur des camions. Julien peut voir les positions sur le site du loueur, mais les récupérer, c'est autre chose : il faut relire le contrat, puis

négocier.

Le propriétaire juridique d'une donnée, celui qui a des droits dessus, n'est pas toujours celui qui l'utilise tous les jours. Pour une donnée qui vient d'un fournisseur, il est même rarement votre client.

Deuxième surprise : le chemin impose le rythme

Le loueur finit par accepter un export. Un seul par jour, à minuit.

Le rêve de prévenir le client en temps réel s'arrête là. Aucune architecture ne rendra « temps réel » une donnée qui arrive une fois par nuit. Julien a deux choix : renégocier un accès direct, et payer pour, ou changer la décision et prévenir les clients le lendemain.

Le mode d'accès (API à la demande, export de fichier, flux continu, saisie à la main) fixe la fraîcheur de la donnée. On le découvre avant de dessiner, pas après.

Troisième surprise : la donnée a un défaut

Les horaires de livraison sont saisis par les chauffeurs sur une tablette. En regardant de près, une bonne partie des livraisons du jour sont enregistrées à 17h52, 17h53, 17h55. Les chauffeurs remplissent tout en fin de tournée, sur le parking.

L'équipe informatique n'en savait rien. Les chefs d'agence, eux, le savaient depuis des années.

La qualité d'une donnée se demande à ceux qui la produisent. Trois questions suffisent pour commencer : est-elle complète, est-elle à jour, est-elle cohérente avec les autres sources ?

Quatrième surprise : impossible de relier les deux

Le loueur identifie chaque camion par son numéro de châssis. Le logiciel de tournées utilise l'immatriculation. La table de correspondance entre les deux existe… dans un fichier Excel tenu à la main par une assistante.

Deux sources sans identifiant commun ne se croisent pas, quel que soit l'outil.

Et combien ça pèse ?

Dernière question avant de chiffrer quoi que ce soit : le volume. On le calcule, terme par terme : nombre de camions, fois fréquence d'envoi, fois taille d'un message, fois durée. On écrit chaque hypothèse à côté. Un ordre de grandeur juste vaut mieux qu'un chiffre précis sorti de nulle part.

C'est l'exercice qui suit.

En résumé

- Une donnée a un propriétaire juridique, qui n'est pas forcément celui qui la produit ni celui qui l'utilise.
- Le mode d'accès fixe la fraîcheur : un export nocturne ne deviendra jamais du temps réel.
- La qualité se demande à ceux qui produisent la donnée, pas à l'informatique.
- Deux sources ne se croisent que si elles partagent un identifiant.
- La volumétrie se calcule terme par terme, avec une hypothèse écrite pour chacun.

Exercice flash, 5 minutes

Seul, sur papier, en posant chaque terme. Les 500 camions de Julien envoient une position GPS toutes les 30 secondes, chaque message pèse 200 octets. Quelle volumétrie par jour, et par an ?

Déroulé

11h30. Sortie d'information R1, puis 15 minutes pour mettre à jour le registre, corriger L1 et écrire l'entrée R1 du journal.

11h45 à 12h05. Capsule : l'histoire de Julien, et l'exercice.

12h05 à 13h. Début de L2 avec ce que vous savez déjà.

14h. Sortie d'information R2, puis registre et entrée R2 du journal.

14h15 à 15h30. L2 complète, avec la volumétrie calculée, puis rendu 1.

Livrable L2 : inventaire des données

Un tableau d'au moins 8 sources, avec ces colonnes, dans cet ordre :

Source	Propriétaire juridique	Responsable opérationnel	Mode d'accès	Fréquence	Volumétrie annuelle (calcul posé)	Donnée de santé	Qualité connue ou supposée	Justification
						oui / non		pièce, sortie ou hypothèse

Sous le tableau, trois données que vous voudriez avoir et que vous n'avez pas, avec ce que leur absence vous coûte.

À la fin de la séance

- L2, inventaire des données
- L1 corrigée après R1
- Registre à jour
- Entrées R1 et R2 du journal

L'ensemble, avec l'entrée R0, part au rendu 1, jeudi à 15h30, dans le devoir Teams. Une photo ou un PDF suffit. C'est l'état de votre groupe ce jeudi soir, et il sera comparé à votre rendu du 29 novembre.