Séance 4 : Architecture et chiffrage

Lundi 30 novembre, 11h30 à 19h, présentiel. Copie 2 à 11h30. Sorties d'information à 14h et à 18h. Rendu 4 à 19h.

Sommaire

- Les règles
- Première histoire : Sophie et le rapport du 5 du mois
  - Une architecture très moderne
  - La question qui change tout
  - Qui voit quoi, et à quelle étape ?
  - Où héberger, et qui fait tourner ?
- Deuxième histoire : Marc et le budget sans équipe
  - Un chiffrage soigné
  - Le stockage, refait au crayon
  - Six mois après la mise en service
- En résumé
- Exercices flash, 5 minutes chacun
- Les bases à garder sous la main
  - Les cinq étages d'une plateforme de données
  - Lots, micro-lots, flux
  - Lac, entrepôt, lakehouse
  - Le médaillon et l'accès aux données
  - Où héberger
  - Chiffrer
- Déroulé
- Livrable L4 : architecture et chiffrage
- À la fin de la séance

Les règles

Chaque brique d'architecture répond à une contrainte nommée. Si vous ne savez pas dire quelle contrainte justifie une brique, la brique est de trop.

Un chiffrage se vérifie à la main. Si vous ne savez pas refaire votre chiffre à voix haute, vous ne savez pas d'où il vient.

Première histoire : Sophie et le rapport du 5 du mois

Une architecture très moderne

Sophie est data engineer chez un fournisseur d'énergie. La direction demande un rapport sur la consommation de ses clients, par région. L'équipe se lance avec enthousiasme : bus de messages, calcul en continu, tableaux de bord rafraîchis à la seconde. C'est moderne, c'est ce que tout le monde fait.

Six mois plus tard, Sophie est d'astreinte une nuit sur trois. Le flux tombe, il faut le relancer, la facture de calcul grimpe chaque mois.

La question qui change tout

Une nouvelle responsable arrive et pose une seule question : « Ce rapport, quand est-il lu ? »

Réponse : une fois par mois, le 5, en comité de direction.

Un traitement chaque nuit aurait suffi, pour une fraction du coût et sans astreinte. Le temps réel ne se choisit pas par principe. Il se justifie par une décision qui ne peut pas attendre.

Quelques mois plus tard, la même entreprise veut détecter les compteurs en panne en moins de cinq minutes. Là, le flux est justifié. Une même plateforme a souvent les deux, et c'est à chaque fois la décision qui tranche. La source aussi pose sa limite : une donnée exportée une fois par nuit ne sera jamais temps réel.

Qui voit quoi, et à quelle étape ?

L'architecture de Sophie suit le modèle médaillon que vous connaissez : bronze pour la donnée brute telle qu'elle arrive, silver pour la donnée nettoyée, gold pour la donnée prête à l'usage d'un métier.

Un jour, un stagiaire fait une requête sur la couche bronze et tombe sur les noms, adresses et consommations de milliers de clients. Personne n'avait décidé qui pouvait accéder au bronze, ni à quel moment on retirait les noms.

À quelle couche pseudonymise-t-on, et qui a le droit de voir ce qu'il y a avant ? C'est une décision juridique autant que technique, et elle se prend en dessinant le schéma.

Où héberger, et qui fait tourner ?

Pour des données sensibles, héberger, c'est choisir une certification : un cloud certifié, ou des serveurs sur site certifiés. La fin d'un contrat d'hébergement est le moment où ce choix se rouvre.

Et pour chaque brique, la même question : l'acheter, ou la construire ? Une brique achetée coûte une licence et une dépendance. Une brique construite coûte une équipe qui la maintient, y compris à 3h du matin. Le bon choix dépend moins de la technologie que des gens que vous aurez pour la faire vivre.

Deuxième histoire : Marc et le budget sans équipe

Un chiffrage soigné

Marc travaille chez un fabricant de pièces automobiles. Il présente le budget d'une plateforme qui doit collecter les données des machines de trois usines, pour anticiper les pannes. Les serveurs, le stockage, les licences : tout est chiffré. 40 000 € par an d'infrastructure. Le comité valide.

Le stockage, refait au crayon

Pour le stockage, Marc a pris le volume brut : 10 To par an. Mais il faut dérouler le calcul jusqu'au bout :

- **Rétention.** On garde trois ans, donc 30 To.
- **Compression.** Les formats de stockage divisent ici le volume par quatre, donc 7,5 To.
- **Réplication.** Chaque donnée est copiée trois fois pour la sécurité, donc 22,5 To.

Sans ces étapes, le chiffre est faux d'un facteur deux ou trois, dans un sens ou dans l'autre. Et chaque coefficient s'écrit avec sa source.

Six mois après la mise en service

Le budget prévoyait « un peu de maintenance ». Mais une source change de format, un flux tombe un vendredi soir, personne n'est là pour le relancer. Les métiers arrêtent de regarder des tableaux de bord qui ne sont plus à jour. La plateforme est abandonnée.

L'équipe qui manquait, un data engineer et un analyste pour la faire tourner, aurait coûté environ 150 000 € par an. Presque quatre fois l'infrastructure. C'est presque toujours le poste le plus lourd, et le plus souvent oublié.

En résumé

- Lots ou flux : c'est la décision métier qui tranche, et la source qui pose la limite.
- À chaque couche du médaillon, on décide qui accède à quoi, et où l'on pseudonymise.
- Héberger des données sensibles, c'est choisir une certification. Acheter ou construire, c'est choisir qui maintiendra.
- Un chiffrage couvre au moins quatre postes : stockage, calcul, licences, équipe.
- Le stockage se déroule jusqu'au bout : brut, rétention, compression, réplication.
- Chaque nombre a son hypothèse écrite à côté.

Exercices flash, 5 minutes chacun

Après l'histoire de Sophie. Lots ou flux, et pourquoi ?

1. La facturation mensuelle des clients d'un opérateur télécom.
2. La détection de fraude sur un paiement par carte.
3. Le tableau de bord des ventes de la veille, lu chaque matin à 9h.

Après l'histoire de Marc. Une plateforme reçoit 50 Go par jour. On garde 5 ans, on compresse d'un facteur 5, on réplique en 3 exemplaires. Quel stockage faut-il prévoir à 5 ans ?

Les bases à garder sous la main

Cette fiche ne se récite pas. Elle sert pendant l'atelier, pour dessiner et chiffrer L4 sans aller chercher ailleurs.

Les cinq étages d'une plateforme de données

Quelle que soit la technologie, on retrouve toujours les mêmes étages. Votre schéma doit les faire apparaître.

1. **Les sources** : logiciels métiers, capteurs, fichiers, partenaires.

2. **L'ingestion** : comment la donnée entre, par lots (un fichier chaque nuit) ou en flux (des messages en continu).
3. **Le stockage** : où elle est conservée, et sous quelle forme.
4. **Le traitement** : nettoyage, croisement, calcul des indicateurs, entraînement des modèles.
5. **L'exposition** : ce que voient les métiers, tableau de bord, liste, alerte, API.

À chaque étage, deux questions : qui y a accès, et à quelle fréquence la donnée y passe.

Lots, micro-lots, flux

Mode	Fraîcheur	Coût et complexité	Quand le choisir
Lots	Quelques heures à un jour	Faible	La décision se prend chaque jour ou moins souvent
Micro-lots	Quelques minutes	Moyen	On veut du quasi temps réel sans astreinte lourde
Flux	Quelques secondes	Élevé, astreinte à prévoir	La décision ne peut pas attendre : panne, fraude, alerte patient

Lac, entrepôt, lakehouse

- **Le lac de données** stocke tout, brut, dans des fichiers, à bas coût. Pratique pour garder l'historique, difficile à interroger proprement.
- **L'entrepôt de données** stocke des données structurées, prêtes à interroger en SQL. Confortable pour les métiers, plus cher et plus rigide.
- **Le lakehouse** combine les deux : des fichiers à bas coût, avec une couche qui permet de les interroger comme des tables. C'est ce que vous avez manipulé en Spark avec Delta.

Les formats en colonnes comme Parquet ou Delta compressent bien : un facteur 3 à 10 par rapport à du CSV ou du JSON, selon les données.

Le médaillon et l'accès aux données

Couche	Contenu	Qui y accède, en règle générale
Bronze	La donnée brute, telle qu'elle arrive, identifiants compris	Les data engineers, et personne d'autre
Silver	La donnée nettoyée, conformée, pseudonymisée	Les data engineers, les data scientists, les analystes habilités
Gold	Les indicateurs et tables prêts pour un usage métier	Les métiers, chacun sur son périmètre

La pseudonymisation se place au plus tôt, en général au passage de bronze à silver. La table de correspondance entre identifiants et pseudonymes se garde à part, avec un accès très restreint.

Où héberger

Option	Ce que vous gérez	Ce que vous achetez
Sur site	Tout : serveurs, réseau, sécurité, sauvegardes	Rien, mais il faut l'équipe

Option	Ce que vous gérez	Ce que vous achetez
Cloud, infrastructure (IaaS)	Systèmes, logiciels, données	Des machines et du stockage à la demande
Cloud, plateforme (PaaS)	Vos traitements et vos données	Des services prêts à l'emploi : base, calcul, orchestration
Logiciel en service (SaaS)	Le paramétrage et l'usage	Une application complète

Pour des données de santé, l'option retenue doit être certifiée HDS pour l'activité concernée. Les grands fournisseurs de cloud et plusieurs acteurs français le sont : la vérification se fait dans la liste publiée par l'Agence du numérique en santé.

Chiffrer

- **Les quatre postes minimum** : stockage, calcul, licences, équipe de run.
- **Investissement ou fonctionnement.** Des serveurs achetés sont un investissement, amorti sur plusieurs années. Le cloud et les licences sont des coûts de fonctionnement, payés chaque mois. Les deux ne se comparent qu'en coût total sur la même durée, trois ans par exemple.
- **La formule du stockage** : volume brut par an × années de rétention ÷ facteur de compression × nombre de copies.
- **Les unités** : 1 Go = 1 000 Mo, 1 To = 1 000 Go. Dites-le si vous comptez en 1 024.
- **Des ordres de grandeur** : le stockage objet standard coûte de l'ordre de 20 à 25 € par To et par mois, beaucoup moins en archivage. Un data engineer coûte autour de 75 k€ par an chargé, un prestataire autour de 650 € par jour.

Déroulé

11h30 à 12h15. Copie 2, sur table, individuelle.

12h15 à 13h. Retour collectif sur les AIPD rendues.

14h. Sortie d'information R4, registre et entrée R4 du journal.

14h15 à 14h35. Capsule : l'histoire de Sophie, et l'exercice.

14h35 à 15h30. Schéma et fiches de décision.

15h45 à 16h05. Capsule : l'histoire de Marc, et l'exercice.

16h05 à 19h. Chiffrage, puis finalisation de L4.

18h. Sortie d'information R5. Vous avez une heure pour écrire son entrée du journal et boucler le rendu 4.

Livrable L4 : architecture et chiffrage

Un schéma sur une page. Toutes les sources de L2. Les couches bronze, silver et gold. L'endroit où l'on pseudonymise. L'hébergement et sa certification. Chaque flux annoté lots ou flux, avec sa fréquence.

Trois fiches de décision, une demi-page chacune. Deux sont imposées : l'hébergement, et le traitement des flux des capteurs. La troisième est libre.

Rubrique	Contenu
Contexte	La question à trancher, en deux phrases
Options	Au moins deux, décrites honnêtement
Décision	L'option retenue
Ce qu'on perd	Ce que l'option écartée aurait apporté
Ce qui tranche	La sortie d'information ou l'hypothèse qui fait pencher la balance

Un chiffrage annuel et à trois ans. Stockage, calcul, licences, équipe de run, total. Chaque nombre a son hypothèse à côté. Les volumes sont cohérents avec L2, et si ce n'est pas le cas, l'écart est expliqué.

À la fin de la séance

- L4 : schéma, trois fiches de décision, chiffrage
- Registre à jour
- Entrées R4 et R5 du journal

L'ensemble part au rendu 4, lundi à 19h, dans le devoir Teams.